

לען גולן - IMC 1 סיכום

ההכרזת הערך א- x מושגת על ידי הטענה $\neg A_x$, כלומר $\neg A_x \rightarrow \perp$. נשים לב כי $\neg A_x \rightarrow \perp$ מושגת על ידי הטענה $\neg A_x$ בלבד, ולכן $\neg A_x \rightarrow \perp$ מושגת על ידי הטענה $\neg A_x$ בלבד.

הוכחה:

$\langle u, v \rangle = \langle Au, Av \rangle$: $\forall u, v \in V$ \exists $C > 0$ $\forall \epsilon > 0$, $\exists N \in \mathbb{N}$ $\forall n \geq N$ $\|A^{-1}u\|_E \leq C \|u\|_E + \epsilon \|u\|_E$

$$\forall v \in V \quad \delta \parallel A_v \parallel = \parallel v \parallel \quad \text{and} \quad \int_{\partial D} \parallel v \parallel$$

$\forall v \in V \quad \delta = \|Av\| = \|v\| \quad \text{וגו}$

ג. הוכיחו כי אם $\langle u, v \rangle = 0$ אז $\|u + v\| = \sqrt{\|u\|^2 + \|v\|^2}$

: P "PNEU BPS C-15/101K 6CN 20320 28 S/CI

$$\|v\| = \sqrt{v \cdot v} = \sqrt{Av \cdot Av} = \|Av\|$$

:2 nuke

$$A = \begin{bmatrix} 1 & 1 & 0 \\ -1 & -1 & 2 \end{bmatrix}$$

$\sum_{(u,v) \in E(G)} \deg(u) = 2|E(G)|$

$$P_{\text{Prune}} = \frac{1}{N} \sum_{n=1}^N \frac{1}{2} \left(1 - \frac{\|v_n^t\|_2}{\|v_n^0\|_2} \right)^2$$

$$A^T A = (\underbrace{U \Sigma V^T}_A)^T (\underbrace{U \Sigma V^T}_A) = V \Sigma^T \underbrace{U^T U}_{I} \Sigma V^T = V \Sigma^2 V^T$$

שכ $(\gamma^* \rightarrow f_1 f_2)$ הינה $EVD \rightarrow$ פונקציית פוליה $A^T A$ מתקיים $\sum_i \alpha_i^2 = 1$ ו- $\sum_i \alpha_i \beta_i = 0$

$$A^T A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{bmatrix}$$

$$V \neq 0 \text{ if } \det(A^t A - \lambda I) = 0$$

$$\det(B - \lambda I) = 0$$

$$\det(A^t A - \lambda I) = \begin{vmatrix} 2-\lambda & 0 & 2 \\ 0 & 2-\lambda & -2 \\ 2 & -2 & 4-\lambda \end{vmatrix} =$$

$$= (2-\lambda) \begin{vmatrix} 2-\lambda & -2 \\ -2 & 4-\lambda \end{vmatrix} + 2 \begin{vmatrix} 0 & 2-\lambda \\ 2 & -2 \end{vmatrix} = (2-\lambda)((2-\lambda)(4-\lambda)-4) + 2(-2(2-\lambda))$$

$$= (2-\lambda) \left((2-\lambda)(4-\lambda) - 4 - 4 \right) = (2-\lambda) (\lambda^2 - 6\lambda) = (2-\lambda) \lambda (\lambda - 6)$$

2,0,6 P₁ γγ₁ 10δ

$$\left[\begin{array}{ccc} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{array} \right] \xrightarrow{\text{Add } A_1^T \text{ to } A_2^T} \left[\begin{array}{ccc} 1 & 0 & 1 \\ 0 & 1 & -1 \\ 0 & -1 & 1 \end{array} \right] \xrightarrow{\text{Add } A_2^T \text{ to } A_3^T} \left[\begin{array}{ccc} 1 & 0 & 1 \\ 0 & 1 & -1 \\ 0 & 0 & 0 \end{array} \right] \Rightarrow X_0 = \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix}$$

$$A^t A - 2I \rightarrow \text{the zero eigenvalue} : \lambda = 2 \text{ is P.S.}$$

$$\left[\begin{array}{ccc} 0 & 0 & 2 \\ 0 & 0 & -2 \\ 2 & -2 & 2 \end{array} \right] \rightarrow \left[\begin{array}{ccc} 0 & 0 & 1 \\ 0 & 0 & 0 \\ 1 & -1 & 1 \end{array} \right] \Rightarrow x_2 = \left[\begin{array}{c} 1 \\ 1 \\ 0 \end{array} \right]$$

$$\lambda=6: \begin{bmatrix} -4 & 0 & 2 \\ 0 & -4 & -2 \\ 2 & -2 & -2 \end{bmatrix} \rightarrow \begin{bmatrix} -2 & 0 & 1 \\ 0 & -2 & -1 \\ 1 & -1 & -1 \end{bmatrix} \rightarrow \begin{bmatrix} 0 & -2 & -1 \\ 0 & -2 & -1 \\ 1 & -1 & -1 \end{bmatrix} \rightarrow \begin{bmatrix} 0 & 0 & 0 \\ 0 & -2 & -1 \\ 1 & -1 & -1 \end{bmatrix} \Rightarrow X_6 = \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}$$

$$V_0 = \frac{x_0}{\|x_0\|} = \begin{bmatrix} -\sqrt{3}/3 \\ \sqrt{3}/3 \\ \sqrt{3}/3 \end{bmatrix}, \quad V_2 = \frac{x_2}{\|x_2\|} = \begin{bmatrix} \sqrt{2}/2 \\ \sqrt{2}/2 \\ 0 \end{bmatrix}, \quad V_6 = \frac{x_6}{\|x_6\|} = \begin{bmatrix} \sqrt{6}/6 \\ -\sqrt{6}/6 \\ \sqrt{6}/3 \end{bmatrix}$$

$$\sum^2 = \begin{bmatrix} 6 & & \\ & 2 & \\ & & 0 \end{bmatrix} \Rightarrow \begin{array}{l} \text{: } (8, 1) \rightarrow 3' 26N \quad (1, 1) \quad \sum^2 \rightarrow 3' 16N, 1 \quad / \times 8 \\ \sum = \begin{bmatrix} \sqrt{6} & & \\ & \sqrt{2} & \\ & & 0 \end{bmatrix} \end{array}$$

$$V = \begin{bmatrix} V_0 & V_1 & V_2 \end{bmatrix} \quad \text{וגם נזכיר}$$

$$V = \begin{bmatrix} \sqrt{6}/6 & \sqrt{2}/2 & -\sqrt{3}/3 \\ -\sqrt{6}/6 & \sqrt{2}/2 & \sqrt{3}/3 \\ \sqrt{6}/3 & 0 & \sqrt{3}/3 \end{bmatrix}$$

• Σ הינה קבוצה של מילים על האלפבית Σ .

$$A \cdot V = U\Sigma = \begin{bmatrix} 1 & 1 & 1 \\ u_1 & u_2 & u_3 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} \sqrt{6} & & \\ & \sqrt{2} & \\ & & 0 \end{bmatrix} = \begin{bmatrix} \sqrt{6} \cdot u_1 & \sqrt{2} \cdot u_2 & 0 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$

$$AV = \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \end{bmatrix} \begin{bmatrix} \frac{\sqrt{6}}{6} & \frac{\sqrt{2}}{2} & -\frac{\sqrt{3}}{3} \\ -\frac{\sqrt{6}}{6} & \frac{\sqrt{2}}{2} & \frac{\sqrt{3}}{3} \\ \frac{\sqrt{6}}{3} & 0 & \frac{\sqrt{3}}{3} \end{bmatrix} = \begin{bmatrix} 0 & \sqrt{2} & 0 \\ \sqrt{6} & 0 & 0 \end{bmatrix}$$

$$\Rightarrow u_1 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad u_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad u_3 = ?$$

$$U = \begin{bmatrix} 0 & 1 & x \\ 1 & 0 & y \end{bmatrix} \quad \text{such}$$

$$\begin{bmatrix} 0 & 1 & x \\ 1 & 0 & y \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 0 \\ xy \end{bmatrix} = \begin{bmatrix} 1+x^2 & xy \\ xy & 1+y^2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad \text{P.D. : } x,y \rightarrow \text{ICNF} \rightarrow 3)$$

$$\therefore x=y=0 \quad \text{P.D.} \\ \text{Eigenvalues} \quad \text{P.N.W} \quad \text{P.K.L}$$

$$A = \underbrace{\begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}_U}_{\Sigma} \underbrace{\begin{bmatrix} \sqrt{6} & & \\ & \sqrt{2} & \\ & & 0 \end{bmatrix}_{\Sigma}}_{V} \underbrace{\begin{bmatrix} \frac{\sqrt{6}}{6} & \frac{\sqrt{2}}{2} & -\frac{\sqrt{3}}{3} \\ -\frac{\sqrt{6}}{6} & \frac{\sqrt{2}}{2} & \frac{\sqrt{3}}{3} \\ \frac{\sqrt{6}}{3} & 0 & \frac{\sqrt{3}}{3} \end{bmatrix}^T}_{V}$$

הנחות $\lambda_1, \dots, \lambda_n$ הן . $C_o = A^T A$ גורגי . $A \in \mathbb{R}^{m \times n}$ גורגי A עלי $: 3$ גורגי
 (פונקציית נורמה) גורגי נורמה . v_1, \dots, v_n גורגי C_o גורגי פונקציית נורמה . $b_k \in \mathbb{R}^n$ גורגי $\lambda_1 > \lambda_2 > \dots > \lambda_n$ גורגי

$$\text{מגדיר } b_0 = \sum_{i=1}^n a_i v_i \quad b_{k+1} = \frac{C_o b_k}{\|C_o b_k\|}$$

$a_i \neq 0$ גורגי

$$\lim_{k \rightarrow \infty} b_k = \pm v_1$$

בגדי פונקציית נורמה גורגי

הנחות $a_i \neq 0$ גורגי $\exists k \in \mathbb{N}$ גורגי $\|b_k\| \leq \|b_{k+1}\|$ גורגי $\|b_k\| \geq \|b_{k+1}\|$ גורגי

$$b_{k+1} = \frac{C_o b_k}{\|C_o b_k\|} = \frac{C_o \cdot \frac{C_o b_{k-1}}{\|C_o b_{k-1}\|}}{\|C_o b_k\|} = \frac{C_o^2 b_{k-1}}{\|C_o b_k\| \cdot \|C_o b_{k-1}\|} = \frac{C_o^3 b_{k-2}}{\|C_o b_k\| \cdot \|C_o b_{k-1}\| \cdot \|C_o b_{k-2}\|}$$

$$b_{k+1} = \frac{C_o^{k+1} b_0}{k} \quad \text{בגדי פונקציית נורמה גורגי}$$

$$b_{k+1} = \frac{c_0^{k+1} b_0}{\prod_{i=0}^k \|c_0 b_i\|}$$

$$b_k = \frac{c_0^k b_0}{\prod_{i=0}^{k-1} \|c_0 b_i\|} \quad k \in \mathbb{N} \text{ if } c_0 b_0 \neq 0$$

for $k \in \mathbb{N}$ if $c_0 b_0 \neq 0$ then b_k is $b_k = \frac{c_0 b_{k-1}}{\|c_0 b_{k-1}\|}$

$$1 = \|b_k\| = \frac{\|c_0^k b_0\|}{\prod_{i=0}^{k-1} \|c_0 b_i\|} \Rightarrow \prod_{i=0}^{k-1} \|c_0 b_i\| = \|c_0^k b_0\| \Rightarrow b_k = \frac{c_0^k b_0}{\|c_0^k b_0\|}$$

$$U = [v_1^T \dots v_n^T]^T \text{ is a } n \times n \text{ matrix. } U^T U = I \text{ and } C_0 = U D U^T$$

$$C_0^k = (U D U^T)^k = \underbrace{(U D U^T) \dots (U D U^T)}_{k \text{ times}} = U D^k U^T$$

$$C_0^k = (U D)(U^T U) D(U^T U) D(U^T U) \dots (U^T U) D(U^T) = U D^k U^T$$

$$D^k = \begin{bmatrix} \lambda_1^k & & \\ & \ddots & \\ & & \lambda_n^k \end{bmatrix}$$

$$C_0^k = [v_1^T \dots v_n^T] \begin{bmatrix} \lambda_1^k & & \\ & \ddots & \\ & & \lambda_n^k \end{bmatrix} \begin{bmatrix} -v_1 \\ \vdots \\ -v_n \end{bmatrix} = [v_1^T \dots v_n^T] \begin{bmatrix} -\lambda_1^k v_1 \\ \vdots \\ -\lambda_n^k v_n \end{bmatrix} = \sum_{i=1}^n \lambda_i^k v_i \otimes v_i$$

$$C_0^k b_0 = \left(\sum_{i=1}^n \lambda_i^k v_i \otimes v_i \right) \cdot b_0 = \sum_{i=1}^n \lambda_i^k (v_i \otimes v_i) b_0 = \sum_{i=1}^n \lambda_i^k (v_i \otimes v_i) \cdot \sum_{j=1}^n a_j v_j = \sum_{i=1}^n \lambda_i^k \sum_{j=1}^n a_j (v_i \otimes v_i) v_j$$

$$= (v_i \otimes v_i) v_j \text{ if } i=j$$

$$\therefore i=j \text{ if } v_i = [x_1 \dots x_n]$$

$$(v_i \otimes v_i) \cdot v_i = \begin{bmatrix} x_1^2 & x_1 x_2 & & \\ x_2 x_1 & x_2^2 & & \\ & & \ddots & \\ & & & x_n^2 \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = (x_1^2 + \dots + x_n^2) \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = v_i$$

$$\text{so } v_i \otimes v_i \cdot v_i = 0 \text{ if } v_i \neq v_j \text{ and } v_i \otimes v_j \cdot v_j = 0 \text{ if } v_i \neq v_j$$

$$C_0^k b_0 = \sum_{i=1}^n \lambda_i^k a_i v_i$$

$$C_0^k b_0 = \lambda_i^k \cdot \sum_{i=1}^n \left(\frac{\lambda_i}{\lambda_1} \right)^k \cdot a_i v_i$$

$$\lim_{k \rightarrow \infty} \frac{c_0 b_0}{\lambda_1^k} = a_1 v_1 \quad \Leftrightarrow \quad i \neq 1 \quad \text{and} \quad \lim_{k \rightarrow \infty} \left(\frac{\lambda_i}{\lambda_1} \right)^k = 0$$

$$b_k = \frac{c_0^k b_0}{\|c_0^k b_0\|} = \frac{c_0^k b_0}{\|\frac{c_0^k b_0}{\lambda^k}\|} : \text{পর্যবেক্ষণ } 10.28 \text{ মিনি}$$

לפ' $B = (v_1, \dots, v_n)$ מתקיים $\sum_{i=1}^n v_i = 0$ אם ורק אם v_1, \dots, v_n מושתתים.

• $\lim_{k \rightarrow \infty} b_k = \pm v_1$

$$\text{答} \quad \lim_{k \rightarrow \infty} b_k = \pm v_1$$

הנ' $f: \mathbb{R}^n \rightarrow \mathbb{R}$ מוגדרת כפונקציית עזר g_C במרחב $\mathbb{R}^{n \times n}$ של מטריצות רציניות, המקיימת $f(x) = g_C(Ux)$ לכל $x \in \mathbb{R}^n$. הערך המינימלי של f מוגדר כערך המינימלי של g_C .

$$f(y) = U \cdot \text{diag}(y) U^T x$$

$$\text{diag}(y) = \begin{bmatrix} y_1 & & & \\ & y_2 & & \\ & & \ddots & \\ & & & y_n \end{bmatrix} \quad \text{a diagonal matrix with } y_i \text{ on the diagonal}$$

$x = (x_1, \dots, x_n)^T$ /no/ $y = (y_1, \dots, y_n)$ /le/ $f(y) = B^T y + b$ /no/ $B = U \text{diag}(y) U^T$ /no/ $i \in \{1, \dots, n\}$

$$f_i(y) = f(y)_i = (Bx)_i = R_i(B) \cdot x$$

-B \in C_n \Rightarrow $i \rightarrow nR_i$ \Rightarrow $R_i(B) \geq 0$
 $\therefore R_i(B) \geq -\delta > -10^2 > -10^{13} N^3 \approx 10^{-3}$

$$\text{diag}(y) \cdot U^T = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix} \begin{bmatrix} -u_1 - \\ \vdots \\ -u_n - \end{bmatrix} = \begin{bmatrix} -y_1 u_1 - \\ -y_2 u_2 - \\ \vdots \\ -y_n u_n - \end{bmatrix}$$

$$U \operatorname{diag}(y) U^T = [u_1 | \dots | u_n] \begin{bmatrix} -y_1 u_1 \\ \vdots \\ -y_n u_n \end{bmatrix} = \sum_{i=1}^n y_i u_i \otimes u_i = B$$

$$R_i(B) = \sum_{j=1}^n y_j R_i(u_j \otimes u_j) = \sum_{j=1}^n y_j u_{ij} u_j$$

\downarrow

$$R_i(u_j \otimes u_j) = u_{ij} \cdot u_j$$

$$f_i(y_1, \dots, y_n) = R_i(B) \cdot x = \sum_{j=1}^n y_j u_{ij} u_j^\top x$$

$$T(f) = \frac{\partial f_i}{\partial x_j} - \text{tr} \, \text{ad}^T X$$

רינרנין לכו שפ, y_j הינה גורם זהה בפונקציית האפסון. מילויים, y_j מושם כפונקציית אפסון מוגבלת.

$$J_y(f)_{ij} = \frac{\partial f_i}{\partial y_j} = u_{ij} u_j^\top x$$

ו.ע. ב- $j=1$ הינה $u_j = 1$, ו.ע. ב- i,j הינה $u_j = 0$.

$$h(\sigma) = \frac{1}{2} \|f(\sigma) - y\|^2$$

: 5 נסחים

g ב- \mathbb{R} מוגדרת כפונקציית אפסון. $g(\sigma) = \frac{1}{2} \|\sigma - y\|^2$ $g: \mathbb{R}^n \rightarrow \mathbb{R}$ פונקציית אפסון.

$h = g \circ f$

$$J_\sigma(h) = J_\sigma(g \circ f) = J_{f(\sigma)}(g) \cdot J_\sigma(f)$$

רינרנין ר' ב- g מוגדרת כפונקציית אפסון. $g: (\mathbb{R} - \delta, \infty) \rightarrow \mathbb{R}$ מוגדרת כפונקציית אפסון. $\sigma_1, \dots, \sigma_n$

$$g(\sigma) = \frac{1}{2} \sum (\sigma_i - y_i)^2 \Rightarrow \frac{\partial g}{\partial \sigma_i} = \frac{1}{2} \cdot 2(\sigma_i - y_i) \cdot 1 = \sigma_i - y_i$$

$$J_\sigma(g) = [\sigma_1 - y_1, \dots, \sigma_n - y_n]$$

$$J_{f(\sigma)}(g) = [f(\sigma)_1 - y_1, \dots, f(\sigma)_n - y_n]$$

$$f_i(y_1, \dots, y_n) = R_i(B) \cdot x = \sum_{j=1}^n y_j u_{ij} u_j^\top x$$

$$(J_{f(\sigma)}(g))_i = \sum_{j=1}^n \sigma_j u_{ij} u_j^\top x - y_i$$

$$(J_\sigma(f))_{ij} = u_{ij} u_j^\top x$$

: f ב- \mathbb{R}^n מוגדרת כפונקציית אפסון.

$$\Rightarrow J_\sigma(g \circ f)_i = J_{f(\sigma)}(g) \circ C_i(J_\sigma(f)) = \sum_{k=1}^n (J_{f(\sigma)}(g))_k \cdot (J_\sigma(f))_{ki}$$

$$= \sum_{k=1}^n \left(\sum_{j=1}^n \sigma_j u_{kj} u_j^\top x - y_k \right) \cdot u_{ki} u_i^\top x$$

ה- $J_\sigma(f)$ מוגדרת כפונקציית אפסון. $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ מוגדרת כפונקציית אפסון.

6. Calculate the Jacobian of the softmax function $S: \mathbb{R}^d \rightarrow [0, 1]^k$

: 6 נסחים

$$e^{x_j}$$

6. Calculate the Jacobian of the softmax function $S : \mathbb{R}^d \rightarrow [0, 1]^k$

:6 75ke

$$\frac{\partial S(x)_i}{\partial x_j} = J_x(S)_{ij}$$

$$S(x)_i = \frac{e^{x_i}}{\sum_{l=1}^k e^{x_l}}$$

$f(x_j) \rightarrow$ x_j \rightarrow $\frac{1}{f(x)}$ \rightarrow $\frac{f'(x)}{(f(x))^2}$ $\cdot x_j \rightarrow$ $\frac{-e^{x_i} \cdot e^{x_j}}{(\sum_{l=1}^k e^{x_l})^2}$

$$\left(\frac{1}{f(x)} \right)' = -\frac{f'(x)}{(f(x))^2}$$

$$\frac{\partial S(x)_i}{\partial x_i} = \frac{e^{x_i} \cdot \sum_{l=1}^k e^{x_l} - e^{x_i} \cdot e^{x_i}}{\left(\sum_{l=1}^k e^{x_l} \right)^2} = \frac{e^{x_i} \cdot \sum_{\substack{l=1 \\ l \neq i}}^k e^{x_l}}{\left(\sum_{l=1}^k e^{x_l} \right)^2}$$

$$J_x(S)_{ij} = \begin{cases} \frac{-e^{x_i} \cdot e^{x_j}}{\left(\sum_{l=1}^k e^{x_l} \right)^2} & : i \neq j \\ \frac{e^{x_i} \cdot \sum_{\substack{l=1 \\ l \neq i}}^k e^{x_l}}{\left(\sum_{l=1}^k e^{x_l} \right)^2} & : i = j \end{cases}$$

:7 75ke

7. Let $f : \mathbb{R}^d \rightarrow \mathbb{R}$ be defined as $f(x, y) = x^3 - 5xy - y^5$. Calculate the Hessian of f .

$$\begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{bmatrix} \quad \text{23' CN} \quad \text{23' CN} \quad \text{10077} \quad f : \mathbb{R}^2 \rightarrow \mathbb{R} \quad \text{75ke}$$

$$\frac{\partial^2 f}{\partial x^2} = \frac{\partial^2 (x^3 - 5xy - y^5)}{\partial x^2} = \frac{\partial (3x^2 - 5y)}{\partial x} = 6x$$

$$\frac{\partial^2 f}{\partial y \partial x} = \frac{\partial^2 f}{\partial x \partial y} = \frac{\partial^2 (x^3 - 5xy - y^5)}{\partial x \partial y} = \frac{\partial (-5x - 5y^4)}{\partial x} = -5$$

$$\frac{\partial^2 F}{\partial y \partial x} = \frac{\partial^2 F}{\partial x \partial y} = \frac{\partial^2 (x^3 - 5xy - y^5)}{\partial x \partial y} = \frac{\partial (-5x - 5y^4)}{\partial x} = -5$$

$$\frac{\partial^2 F}{\partial^2 y} = \frac{\partial^2 (x^3 - 5xy - y^5)}{\partial^2 y} = \frac{\partial (-5x - 5y^4)}{\partial y} = -20y^3$$

$$\begin{bmatrix} 6x & -5 \\ -5 & -20y^3 \end{bmatrix}$$

• *decreasing function* $\Leftrightarrow f(x_1) > f(x_2)$ if $x_1 < x_2$

8. Let $x_1, x_2, \dots \stackrel{iid}{\sim} \mathcal{P}$ be a sample of infinity size drawn from some probability distribution function \mathcal{P} with finite expectation and variance. Show that the sample mean estimator $\hat{\mu}_n = \frac{1}{n} \sum x_i$ calculated over the first n samples is a consistent estimator. Hint: for any given fixed value of $n \in \mathbb{N}$ bound from above the probability of deviating more than ε .

$$\lim_{n \rightarrow \infty} P(|\hat{\mu}_n(x_1, \dots, x_n) - \mu| > \varepsilon) = 0$$

• P → be → be

לכל x_1, \dots, x_n מ- \mathbb{R}^n נקבע $\hat{\mu}_n(x_1, \dots, x_n) = \mu$.

אנו מודים לך על תרומותך ותומך במתמטיקה. מטרתנו היא לסייע לך בלמידה מושלמת. אם יש לך שאלות או מושג'ה, אנא נאלה. מילויים יתבצעו מידי.

$$\mathbb{E}(\hat{\mu}_n(x_1, \dots, x_n)) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) = \frac{1}{n} \cdot \sum_{i=1}^n \mu = \mu$$

$$P(|\hat{\mu}_n - E(\hat{\mu}_n)| > \varepsilon) \leq \frac{Var(\hat{\mu}_n)}{\varepsilon^2}$$

$\text{Var}(X_i) = \sigma^2$ פ'סונ סיכ, ד' מילון שער ערך אמצעי μ וסטייה תקנית σ

$$\text{Var}(\bar{x}_n(x_1, \dots, x_n)) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n x_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(x_i) = \frac{1}{n^2} \cdot n \cdot \sigma^2 = \frac{\sigma^2}{n}$$

m̥y̥d m̥iʒp̥ var-ə n̥o n̥iŋdʒ p̥aŋ s̥la , m̥iɛs̥a n̥iŋ p̥o f̥xiŋ e p̥iːs̥

$$P(|\hat{f}_n(x_1, \dots, x_n) - \mu| > \varepsilon) \leq \frac{\frac{\sigma^2}{n}}{\varepsilon^2} = \frac{\sigma^2}{n \cdot \varepsilon^2} \xrightarrow{n \rightarrow \infty} 0 \quad : \varepsilon > 0 \text{ ֆախան աւրի այդ}$$

$$\lim_{n \rightarrow \infty} P(|\hat{\mu}_n(x_1, \dots, x_n) - \mu| > \varepsilon) = 0$$

9. Let $\mathbf{x}_1, \dots, \mathbf{x}_m \stackrel{iid}{\sim} \mathcal{N}(\mu, \Sigma)$ be m observations sampled i.i.d from a multivariate Gaussian with expectation of $\mu \in \mathbb{R}^d$ and a covariance matrix $\Sigma \in \mathbb{R}^{d \times d}$. Derive the log-likelihood function of $\mathcal{N}(\mu, \Sigma)$. Hint: follow the approach used to derive the likelihood function for the univariate case.

לכן $X \sim N(\mu, \Sigma)$ פירושו אינטuitיבית הוא ש- X מוגדר כפונקציה של n גורמים.

$$f(x) = \frac{1}{\sqrt{(2\pi)^d |\Sigma|}} \cdot \exp\left(-\frac{1}{2}(x-\mu)^\top \Sigma^{-1}(x-\mu)\right)$$

$$L(\phi | x_i) = f_\phi(x_i) = \frac{1}{\sqrt{(2\pi)^d |\hat{\Sigma}|}} \cdot \exp\left(-\frac{1}{2}(x_i - \hat{\mu})^\top \hat{\Sigma}^{-1}(x_i - \hat{\mu})\right)$$

ההסתדרות \rightarrow הינה Θ פונקציית אינטגרציה של π . $\Theta(\pi)$ מוגדרת כ-

$$L(\theta | x_1, \dots, x_n) = \prod_{i=1}^n f_{\theta}(x_i)$$

: log-likelihood \rightarrow -3p/10

$$\log L(\theta | x_1, \dots, x_n) = \log \left(\prod_{i=1}^n f_\theta(x_i) \right) = \sum_{i=1}^n \log f_\theta(x_i) =$$

$$= n \log \left(\frac{1}{\sqrt{(x_i - \bar{x})^T \hat{\Sigma}^{-1} (x_i - \bar{x})}} \right) + \sum_{i=1}^n (-\frac{1}{2} (x_i - \bar{x})^T \hat{\Sigma}^{-1} (x_i - \bar{x}))$$

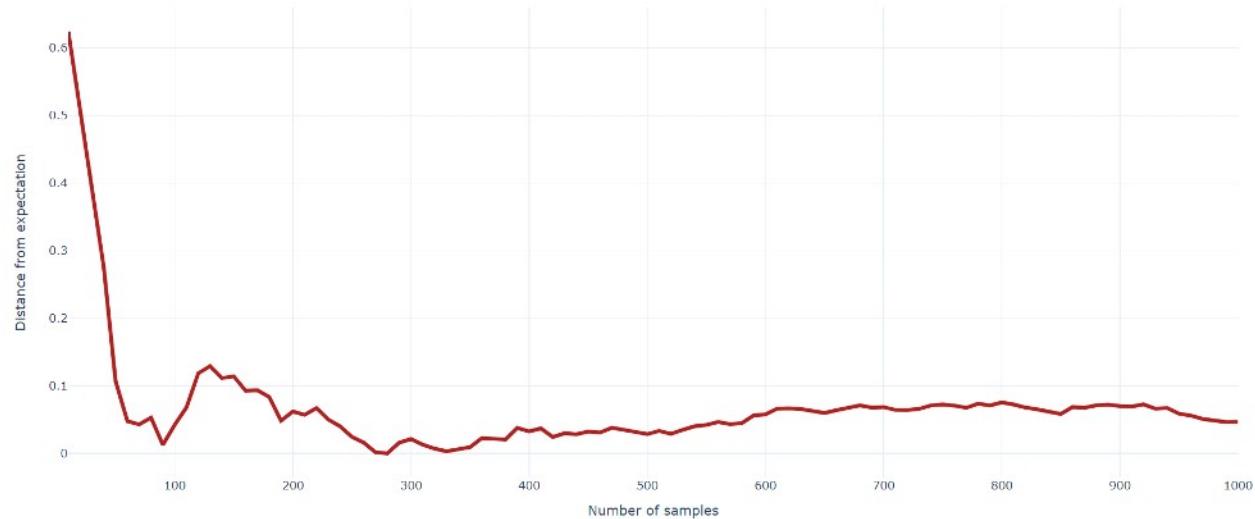
גרפים לחילוק המעשי:

שאלה: 1

(0.9752096659781323 , 9.954743292509804)

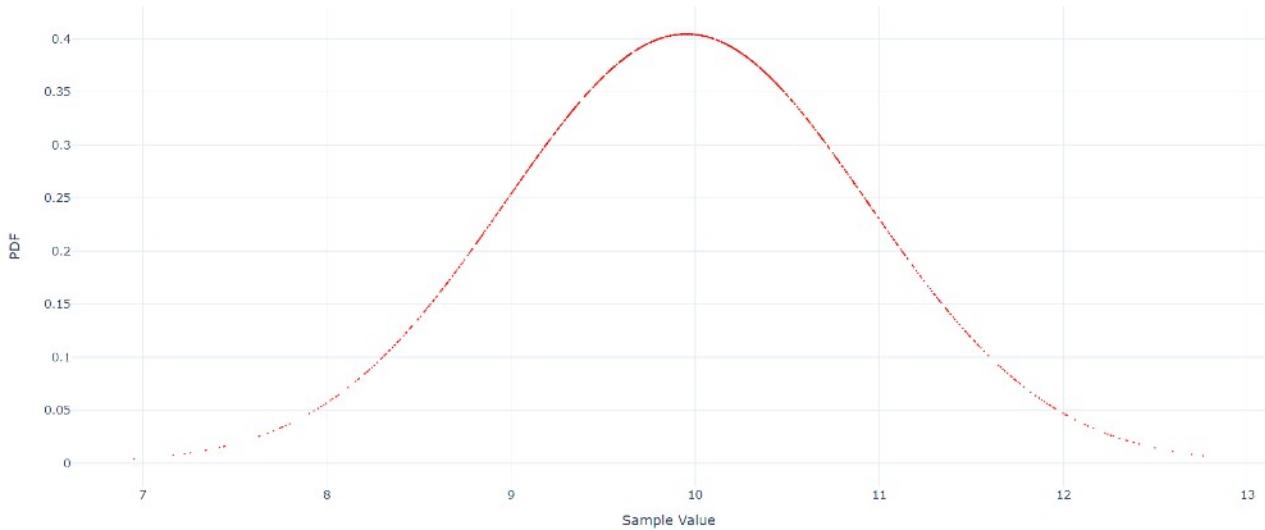
שאלה: 2

Absolute distance between estimated- and true expectation



שאלה: 3

PDF for each sample drawn



המגרף ניתן לראות שפונקציית הצפיפות המתקבלת היא בצורה של ההסתפלגות נורמלית עם ממוצע שטוחה רק במעט מהערך האמתי של 10. זה הגיוני כיון שההדגימות אכן הגיעו מהסתפלגות נורמלית והתוחלת של פונקציית ההסתפלגות ממנה נגזרו הייתה 10.

שאלה: 4

[0.02038981- 3.9932571 0.04313959- 0.02282878-]

,[0.04557631130140597 ,0.005877889086032535- ,1.974182797387516 ,0.16634443759233586] ,[0.4628827064594544 ,0.030275629165979034- ,0.16634443759233586 ,0.916676077499685]]
[[0.9725372963099224 ,0.020366857161867046- ,0.04557631130140597 ,0.4628827064594544] ,[0.020366857161867046- ,0.9796027125646046 ,0.005877889086032535- ,0.030275629165979034-]]

שאלה 5



מAGRף למדנו שהערך המקסימלי של log-likelihood נמצא באזורי של $f_1=0, f_3=4$. אלו אכן הפרמטרים האמתיים של ההסתפלגות ממנה הדימויות הגיעו, ולכן הגיוני שלערכיהם אלו תהיה נראות מקסימלית.

שאלה 6

The f_1, f_3 values which yielded maximal likelihood: -0.050 3.969