

תרגיל 1

Thursday, March 10, 2022 17:20

שם: הדר חבר
תז: 206996761

ת. גולן טifice - IML 1 סט

$$\|Ax\| = \|x\| \quad x \in V \quad \text{Proof} \quad \text{Since } \|Ax\|^2 = \langle Ax, Ax \rangle = \langle x, A^T Ax \rangle = \langle x, \|A\|^2 x \rangle = \|A\|^2 \|x\|^2$$

ליכוד:

$\langle u, v \rangle = \langle Au, Av \rangle$: $u, v \in V$ if \exists $A \in \mathbb{R}^{n \times n}$ such that $\langle u, v \rangle = \langle Au, Av \rangle$

בג' א. הגדלה של מטריצה אינטגרלית בפונקציית שערת גבולות: $\|Av\| = \sqrt{\langle Av, Av \rangle}$, $\|v\| = \sqrt{\langle v, v \rangle}$: מושג זה מוגדר כמטריצה אינטגרליתoline�ן. בפונקציית שערת גבולות: $\|P_n\| = \sqrt{\lambda_{\max}(P_n)}$, $\|P_n - P_{n-1}\| = \sqrt{\lambda_{\max}(P_n - P_{n-1})}$.

$$\|v\| = \sqrt{v \cdot v} = \sqrt{Av \cdot Av} = \|Av\|$$

11

:2 nuke

$$A = \begin{bmatrix} 1 & 1 & 0 \\ -1 & -1 & 2 \end{bmatrix}$$

$\sum_{\text{pair } (u,v) \in E(G)} \deg(u) \deg(v)$

Perne Skyr i k. . A = u \sum v^t e

$$A^T A = (\mathbf{U} \Sigma \mathbf{V}^T)^T (\mathbf{U} \Sigma \mathbf{V}^T) = \mathbf{V} \Sigma^T \underbrace{\mathbf{U}^T \mathbf{U}}_{\mathbf{I}} \Sigma \mathbf{V}^T = \mathbf{V} \Sigma^2 \mathbf{V}^T$$

$$A^T A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{bmatrix}$$

$$V \neq 0 \Rightarrow \text{Sic } B \text{ so } \forall \lambda \text{ PK } \hookrightarrow \\ Bv = \lambda v \quad : \circ \quad \leftarrow \quad \det(A^t A - \lambda I) = 0$$

$$\det(B - \lambda I) = 0 \quad \text{and} \quad (B - \lambda I)v = 0$$

! co co co

$$\det(A^t A - \lambda I) = \begin{vmatrix} 2-\lambda & 0 & 2 \\ 0 & 2-\lambda & -2 \\ 2 & -2 & 4-\lambda \end{vmatrix} =$$

$$= (2-\lambda) \begin{vmatrix} 2-\lambda & -2 \\ -2 & 4-\lambda \end{vmatrix} + 2 \begin{vmatrix} 0 & 2-\lambda \\ 2 & -2 \end{vmatrix} = (2-\lambda)((2-\lambda)(4-\lambda)-4) + 2(-2(2-\lambda))$$

$$= (2-\lambda)((2-\lambda)(4-\lambda)-4) - 4 = (2-\lambda)(\lambda^2 - 6\lambda) = (2-\lambda)\lambda(\lambda-6)$$

2,0,6 P₁) 88₁ 108

$$\left[\begin{array}{ccc} 2 & 0 & 2 \\ 0 & 2 & -2 \\ 2 & -2 & 4 \end{array} \right] \xrightarrow{\text{Row operations}} \left[\begin{array}{ccc} 1 & 0 & 1 \\ 0 & 1 & -1 \\ 0 & -1 & 1 \end{array} \right] \xrightarrow{\text{Row operations}} \left[\begin{array}{ccc} 1 & 0 & 1 \\ 0 & 1 & -1 \\ 0 & 0 & 0 \end{array} \right] \Rightarrow x_0 = \begin{bmatrix} -1 \\ 1 \\ 1 \end{bmatrix}$$

$$A^T A - 2I \rightarrow \text{reduced row echelon form} : \lambda = 2 \quad \text{is } p$$

$$\left[\begin{array}{ccc} 0 & 0 & 2 \\ 0 & 0 & -2 \\ 2 & -2 & 2 \end{array} \right] \rightarrow \left[\begin{array}{ccc} 0 & 0 & 1 \\ 0 & 0 & 0 \\ 1 & -1 & 1 \end{array} \right] \Rightarrow x_2 = \left[\begin{array}{c} 1 \\ 1 \\ 0 \end{array} \right]$$

$$\lambda=6: \begin{bmatrix} -4 & 0 & 2 \\ 0 & -4 & -2 \\ 2 & -2 & -2 \end{bmatrix} \rightarrow \begin{bmatrix} -2 & 0 & 1 \\ 0 & -2 & -1 \\ 1 & -1 & -1 \end{bmatrix} \rightarrow \begin{bmatrix} 0 & -2 & -1 \\ 0 & -2 & -1 \\ 1 & -1 & -1 \end{bmatrix} \rightarrow \begin{bmatrix} 0 & 0 & 0 \\ 0 & -2 & -1 \\ 1 & -1 & -1 \end{bmatrix} \Rightarrow X_6 = \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix}$$

$$V_0 = \frac{x_0}{\|x_0\|} = \begin{bmatrix} -\sqrt{3}/3 \\ \sqrt{3}/3 \\ \sqrt{3}/3 \end{bmatrix}, \quad V_2 = \frac{x_2}{\|x_2\|} = \begin{bmatrix} \sqrt{2}/2 \\ \sqrt{2}/2 \\ 0 \end{bmatrix}, \quad V_6 = \frac{x_6}{\|x_6\|} = \begin{bmatrix} \sqrt{6}/6 \\ -\sqrt{6}/6 \\ \sqrt{6}/3 \end{bmatrix}$$

$$\Sigma^2 = \begin{bmatrix} 6 & & \\ & 2 & \\ & & 0 \end{bmatrix} \Rightarrow \Sigma = \begin{bmatrix} \sqrt{6} & & \\ & \sqrt{2} & \\ & & 0 \end{bmatrix}$$

$$V = \begin{bmatrix} V_0 & V_1 & V_2 \\ V_1 & V_0 & V_3 \\ V_2 & V_3 & V_0 \end{bmatrix} \quad \text{and } C_{N,1} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

$$V = \begin{bmatrix} \frac{\sqrt{6}}{6} & \frac{\sqrt{2}}{2} & -\frac{\sqrt{3}}{3} \\ -\frac{\sqrt{6}}{6} & \frac{\sqrt{2}}{2} & \frac{\sqrt{3}}{3} \\ \frac{\sqrt{6}}{3} & 0 & \frac{\sqrt{3}}{3} \end{bmatrix}$$

: \cup \cap \subset \in \forall \exists \neg \wedge \vee \rightarrow \leftrightarrow $\exists!$ $\forall!$

$$A \cdot V = U\Sigma = \begin{bmatrix} 1 & 1 & 1 \\ u_1 & u_2 & u_3 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} \sqrt{6} \\ \sqrt{2} \\ 0 \end{bmatrix} = \begin{bmatrix} \sqrt{6} \cdot u_1 \\ \sqrt{2} \cdot u_2 \\ 0 \end{bmatrix}$$

$$AV = \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 2 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} \sqrt{6}/6 & \sqrt{2}/2 & -\sqrt{3}/3 \\ -\sqrt{6}/6 & \sqrt{2}/2 & \sqrt{3}/3 \\ \sqrt{6}/3 & 0 & \sqrt{3}/3 \end{bmatrix} = \begin{bmatrix} 0 & \sqrt{2} & 0 \\ \sqrt{6} & 0 & 0 \end{bmatrix}$$

$$\Rightarrow u_1 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} \quad u_2 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \quad u_3 = ?$$

$$U = \begin{bmatrix} 0 & 1 & x \\ 1 & 0 & y \end{bmatrix} \quad S/L$$

$$\begin{bmatrix} 0 & 1 & x \\ 1 & 0 & y \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & 0 \\ xy \end{bmatrix} = \begin{bmatrix} 1+x^2 & xy \\ xy & 1+y^2 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \quad \text{প্রমাণ: } x, y \rightarrow \text{কি? } (13N^{\frac{1}{2}})$$

$$\therefore x=y=0 \quad \text{প্রমাণ: } \text{কি?}$$

$$A = \underbrace{\begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}}_U \underbrace{\begin{bmatrix} \sqrt{6} & & \\ & \sqrt{2} & \\ & & 0 \end{bmatrix}}_{\Sigma} \underbrace{\begin{bmatrix} \sqrt{6}/6 & \sqrt{2}/2 & -\sqrt{3}/3 \\ -\sqrt{6}/6 & \sqrt{2}/2 & \sqrt{3}/3 \\ \sqrt{6}/3 & 0 & \sqrt{3}/3 \end{bmatrix}}_V^T$$

পরিয়া ধী, ..., ধী হ'ল . $C_0 = A^T A$ এবং . $A \in \mathbb{R}^{m \times n}$ হ'ল কি? A ধী হ'ল কি? $C_0 = A^T A$ হ'ল কি? C_0 হ'ল কি? $\lambda_1, \dots, \lambda_n$ হ'ল কি? b_1, \dots, b_n হ'ল কি? $\lambda_1 > \lambda_2 > \dots > \lambda_n$ হ'ল কি? $\lambda_1 > \lambda_2 > \dots > \lambda_n$ হ'ল কি? $\lambda_1 > \lambda_2 > \dots > \lambda_n$ হ'ল কি?

$$\text{সেগুন্ড সূত্র } b_0 = \sum_{i=1}^n a_i v_i \quad b_{k+1} = \frac{C_0 b_k}{\|C_0 b_k\|}$$

$a_1 \neq 0$ হ'ল

$$\lim_{k \rightarrow \infty} b_k = \pm v_1$$

সেগুন্ড সূত্র হ'ল

পুরোটা

বিশেষ করণ করা হ'ল

$$b_{k+1} = \frac{C_0 b_k}{\|C_0 b_k\|} = \frac{C_0 \cdot \frac{C_0 b_{k-1}}{\|C_0 b_{k-1}\|}}{\|C_0 b_k\|} = \frac{C_0^2 b_{k-1}}{\|C_0 b_k\| \|C_0 b_{k-1}\|} = \frac{C_0^3 b_{k-2}}{\|C_0 b_k\| \|C_0 b_{k-1}\| \|C_0 b_{k-2}\|}$$

$$b_{k+1} = \frac{C_0^{k+1} b_0}{\prod_{i=0}^k \|C_0 b_i\|}$$

$$b_k = \frac{C_0^k b_0}{\prod_{i=1}^{k-1} \|C_0 b_i\|}$$

$k \in \mathbb{N}$ হ'ল কি? $\lambda_1 > \lambda_2 > \dots > \lambda_n$ হ'ল কি?

$$b_k = \frac{\sum_{i=0}^{k-1} \|c_i b_i\|}{\prod_{i=0}^{k-1} \|c_i b_i\|} \quad k \in \mathbb{N} \quad \text{for } k \in \mathbb{N}$$

for $k \in \mathbb{N}$ the sum $\sum_{i=0}^{k-1} \|c_i b_i\|$ is called the k -th power of C_0 .

$$1 = \|b_k\| = \frac{\|C_0^k b_0\|}{\prod_{i=0}^{k-1} \|c_i b_i\|} \Rightarrow \frac{\prod_{i=0}^{k-1} \|c_i b_i\|}{\prod_{i=0}^{k-1} \|c_i b_i\|} = \|C_0^k b_0\| \Rightarrow b_k = \frac{C_0^k b_0}{\|C_0^k b_0\|}$$

$U = [v_1 | \dots | v_n]$ is a basis of \mathbb{R}^n . EVD implies $C_0 = U D U^{-1}$.

$$\text{so } C_0^k = U D U^{-1}$$

$$C_0^k = (U D U^{-1})^k = \underbrace{(U D U^{-1})(U D U^{-1}) \dots (U D U^{-1})}_k$$

$$\text{so } U D U^{-1} = U^{-1} D U \Rightarrow U^{-1} D U = I$$

$$C_0^k = (U D)(U^{-1} D U) D(U^{-1} D U) D \dots (U^{-1} D U)(D U^{-1}) = U D^k U^{-1}$$

$$D^k = \begin{bmatrix} \lambda_1^k & \dots & \lambda_n^k \end{bmatrix} \quad \text{so } D^k = \lambda_1^k \dots \lambda_n^k$$

$$C_0^k = [v_1 | \dots | v_n] \begin{bmatrix} \lambda_1^k & & \\ & \ddots & \\ & & \lambda_n^k \end{bmatrix} \begin{bmatrix} -v_1 \\ \vdots \\ -v_n \end{bmatrix} = [v_1 | \dots | v_n] \cdot \begin{bmatrix} -\lambda_1^k v_1 \\ -\lambda_2^k v_2 \\ \vdots \\ -\lambda_n^k v_n \end{bmatrix} = \sum_{i=1}^n \lambda_i^k \cdot v_i \otimes v_i$$

$$C_0^k b_0 = \left(\sum_{i=1}^n \lambda_i^k v_i \otimes v_i \right) \cdot b_0 = \sum_{i=1}^n \lambda_i^k (v_i \otimes v_i) b_0 = \sum_{i=1}^n \lambda_i^k (v_i \otimes v_i) \cdot \sum_{j=1}^n a_j v_j = \sum_{i=1}^n \lambda_i^k \sum_{j=1}^n a_j (v_i \otimes v_i) v_j$$

$$= (v_i \otimes v_i) v_j \rightarrow \text{so } v_i \otimes v_j$$

$$\text{so } i=j \text{ implies } v_i \otimes v_i = v_i v_i^T$$

$$(v_i v_i^T) \cdot v_i = \begin{bmatrix} x_1^2 & x_1 x_2 & \dots & x_1 x_n \\ x_2 x_1 & x_2^2 & \dots & x_2 x_n \\ \vdots & \vdots & \ddots & \vdots \\ x_n x_1 & x_n x_2 & \dots & x_n^2 \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = (x_1^2 + \dots + x_n^2) \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = v_i$$

so $v_i v_i^T \cdot v_i = \lambda_i^k v_i$ for all i .

$$C_0^k b_0 = \sum_{i=1}^n \lambda_i^k a_i v_i$$

$$C_0^k b_0 = \lambda_1^k \cdot \sum_{i=1}^n \left(\frac{\lambda_i}{\lambda_1} \right)^k \cdot a_i v_i$$

so, if $a_i \neq 0$ then $\lambda_i / \lambda_1 \rightarrow 0$ as $i \rightarrow \infty$.

$$\lim_{k \rightarrow \infty} \frac{C_0^k b_0}{\lambda_1^k} = a_1 v_1 \Leftrightarrow i \neq 1 \text{ implies } \lim_{k \rightarrow \infty} \left(\frac{\lambda_i}{\lambda_1} \right)^k = 0$$

$$b_k = \frac{C_0^k b_0}{\|C_0^k b_0\|} = \frac{C_0^k b_0}{\|\lambda_1^k v_1\|} \quad \text{so } b_k \rightarrow a_1 v_1$$

$$b_k = \frac{c_0 b_0}{\|c_k b_0\|} = \frac{|z_k|}{\left\|\frac{c_k b_0}{z_k}\right\|}$$

$\vec{v}_1 \vec{v}_2 \dots \vec{v}_n$ $\vec{w}_1 \vec{w}_2 \dots \vec{w}_m$ $\vec{u}_1 \vec{u}_2 \dots \vec{u}_n$

$$\lim_{k \rightarrow \infty} b_k = \pm v_1$$

ההצגה הינה פונקציית מילוי $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$. מילוי פונקציית מילוי מוגדרת כפונקציה $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ שמקיימת את התכונה $f(x) = y$ עבור כל $x \in \mathbb{R}^n$ וכל $y \in \mathbb{R}^m$.

$$f(y) = U \cdot \text{diag}(y) U^T X$$

$$\text{diag}(y) = \begin{bmatrix} y_1 & & & \\ & y_2 & \ddots & \\ & & \ddots & \\ & & & y_n \end{bmatrix} \quad \text{נילען רצונן} \quad \text{לכז} \quad \text{diag}(y) \quad \text{רלען}$$

• $x = (x_1, \dots, x_n)^T$ /no/ , $y = (y_1, \dots, y_n)$ /no/ . $f_i(y)$ /no/ \rightarrow $f(y)$ /no/ $\in \mathbb{R}^n$ /no/ . $B = \cup_{i=1}^n \text{diag}(y_i) U^T$ /no/ .

$$f_i(y) = f(y)_i = (Bx)_i = R_i(B) \cdot x$$

$$-B \quad \text{sign} \quad \text{se} \quad i \rightarrow \quad \text{sign}(B) \quad \text{sign} \quad R_i(B) \quad \text{sign}(B)$$

$$R_1(B) = -\delta \quad \text{if } B \geq 103N\delta \quad \text{and } 10\delta$$

$$\text{diag}(y) \cdot U^T = \begin{bmatrix} y_1 & & \\ & \ddots & \\ & & y_n \end{bmatrix} \begin{bmatrix} -u_1^- \\ \vdots \\ -u_n^- \end{bmatrix} = \begin{bmatrix} -y_1 u_1^- \\ -y_2 u_2^- \\ \vdots \\ -y_n u_n^- \end{bmatrix}$$

$$U \operatorname{diag}(y) U^T = \begin{bmatrix} | & & | \\ u_1 & \cdots & u_n \\ | & & | \end{bmatrix} \begin{bmatrix} -y_1 u_1 - \\ \vdots \\ -y_n u_n - \end{bmatrix} = \sum_{i=1}^n y_i u_i \otimes u_i = B$$

$$R_i(B) = \sum_{j=1}^n y_j R_i(u_j \otimes u_j) = \sum_{j=1}^n y_j u_{ij} u_j$$

\downarrow

$$R_i(u_j \otimes u_j) = u_{ij} \cdot u_j$$

$$f_i(y_1, \dots, y_n) = R_i(B) \cdot x = \sum_{j=1}^n y_j u_{ij} u_j^\top x$$

$$J_y(f)_{ij} = \frac{\partial f_i}{\partial y_j} = u_{ij} u_j^T x$$

• u be j -th neighbor of u_j , u be i,j -th neighbor of u_{ij} $\forall i,j$

$$h(\sigma) = \frac{1}{2} \|f(\sigma) - y\|^2$$

: 5 задача

• g – σ – y – $f(\sigma)$ – y – $g(\sigma) = \frac{1}{2} \|\sigma - y\|^2$ $g: \mathbb{R}^n \rightarrow \mathbb{R}$ $\sigma \in \mathbb{R}^n$

σ – y – $g(\sigma)$ – g – h – $g \circ f$ – h

$$J_{\sigma}(h) = J_{\sigma}(g \circ f) = J_{f(\sigma)}(g) \cdot J_{\sigma}(f)$$

Рассмотрим для g – σ – y – $g(\sigma) = \frac{1}{2} \|\sigma - y\|^2$, g – σ – y – $g(\sigma) = \frac{1}{2} \|\sigma - y\|^2$ для $\sigma_1, \dots, \sigma_n$

$$g(\sigma) = \frac{1}{2} \sum (\sigma_i - y_i)^2 \Rightarrow \frac{\partial g}{\partial \sigma_i} = \frac{1}{2} \cdot 2(\sigma_i - y_i) \cdot 1 = \sigma_i - y_i$$

$$J_{\sigma}(g) = [\sigma_1 - y_1, \dots, \sigma_n - y_n]$$

$$J_{f(\sigma)}(g) = [f(\sigma)_1 - y_1, \dots, f(\sigma)_n - y_n]$$

$$f_i(y_1, \dots, y_n) = R_i(B) \cdot x = \sum_{j=1}^n y_j u_{ij} u_j^T x$$

$$(J_{f(\sigma)}(g))_i = \sum_{j=1}^n \sigma_j u_{ij} u_j^T x - y_i$$

$$(J_{\sigma}(f))_{ij} = u_{ij} u_j^T x$$

: f – σ – y – x – u – R

$$\Rightarrow J_{\sigma}(g \circ f)_i = J_{f(\sigma)}(g) \circ C_i(J_{\sigma}(f)) = \sum_{k=1}^n (J_{f(\sigma)}(g))_k \cdot (J_{\sigma}(f))_{ki}$$

$$= \sum_{k=1}^n \left(\sum_{j=1}^n \sigma_j u_{kj} u_j^T x - y_k \right) \cdot u_{ki} u_i^T x$$

h – σ – y – x – u – R

6. Calculate the Jacobian of the softmax function $S: \mathbb{R}^d \rightarrow [0, 1]^k$

$$\frac{\partial S(x)_i}{\partial x_j} = J_x(S)_{ij}$$

$$S(\mathbf{x})_j = \frac{e^{x_j}}{\sum_{l=1}^k e^{x_l}}$$

$$S(x)_i = \frac{e^{x_i}}{\sum_{l=1}^k e^{x_l}}$$

$$\sum_{l=1}^k e^{x_l}$$

$f(x_j) \rightarrow$ $\text{if } x_j = k \text{ then } f(x_j) = 0$ $\text{else } f(x_j) = \frac{e^{x_i}}{\sum_{l=1}^k e^{x_l}}$

$$\left(\frac{1}{f(x)} \right)' \rightarrow -\frac{f'(x)}{(f(x))^2}$$

$$\frac{\partial S(x)_i}{\partial x_j} = \frac{-e^{x_i} \cdot e^{x_j}}{\left(\sum_{l=1}^k e^{x_l} \right)^2}$$

• $\partial S(x)_i / \partial x_j$ \rightarrow $\text{if } i=j \text{ then } 1 \text{ else } 0$

$$\frac{\partial S(x)_i}{\partial x_i} = \frac{e^{x_i} \cdot \sum_{l=1}^k e^{x_l} - e^{x_i} \cdot e^{x_i}}{\left(\sum_{l=1}^k e^{x_l} \right)^2} = \frac{e^{x_i} \cdot \sum_{\substack{l=1 \\ l \neq i}}^k e^{x_l}}{\left(\sum_{l=1}^k e^{x_l} \right)^2}$$

$$J_X(S)_{ij} = \begin{cases} \frac{-e^{x_i} \cdot e^{x_j}}{\left(\sum_{l=1}^k e^{x_l} \right)^2} & : i \neq j \\ \frac{e^{x_i} \cdot \sum_{\substack{l=1 \\ l \neq i}}^k e^{x_l}}{\left(\sum_{l=1}^k e^{x_l} \right)^2} & : i = j \end{cases}$$

: 7 make

7. Let $f: \mathbb{R}^2 \rightarrow \mathbb{R}$ be defined as $f(x, y) = x^3 - 5xy - y^5$. Calculate the Hessian of f .

$$\begin{bmatrix} \frac{\partial^2 f}{\partial x^2} & \frac{\partial^2 f}{\partial x \partial y} \\ \frac{\partial^2 f}{\partial y \partial x} & \frac{\partial^2 f}{\partial y^2} \end{bmatrix}$$

2nd order partial derivatives

$f: \mathbb{R}^2 \rightarrow \mathbb{R}$

variables

$$\frac{\partial^2 f}{\partial x^2} = \frac{\partial^2 (x^3 - 5xy - y^5)}{\partial x^2} = \frac{\partial (3x^2 - 5y)}{\partial x} = 6x$$

$$\frac{\partial^2 f}{\partial y \partial x} = \frac{\partial^2 f}{\partial x \partial y} = \frac{\partial^2 (x^3 - 5xy - y^5)}{\partial x \partial y} = \frac{\partial (-5x - 5y^4)}{\partial x} = -5$$

$$\frac{\partial^2 f}{\partial y^2} = \frac{\partial^2 (x^3 - 5xy - y^5)}{\partial y^2} = \frac{\partial (-5x - 5y^4)}{\partial y} = -20y^3$$

$$\begin{bmatrix} 6x & -5 \\ -5 & -20y^3 \end{bmatrix}$$

: 2nd order partial derivatives \in

8. Let $x_1, x_2, \dots \stackrel{iid}{\sim} \mathcal{P}$ be a sample of infinity size drawn from some probability distribution function \mathcal{P} with finite expectation and variance. Show that the sample mean estimator $\hat{\mu}_n = \frac{1}{n} \sum x_i$ calculated over the first n samples is a consistent estimator. Hint: for any given fixed value of $n \in \mathbb{N}$ bound from above the probability of deviating more than ε .

5. ה. הרכבה, ציפוי גוון גומי ופְּנִיר

$$\lim_{n \rightarrow \infty} P(|\hat{\mu}_n(x_1, \dots, x_n) - \mu| > \varepsilon) = 0$$

.P \rightarrow $\exists x \forall y \exists z$ $(x \neq y \wedge x \neq z \wedge y \neq z)$

הנ'ז מושג'ת ע"כ רצוי'ו. מילוי הטענה נובע מכך ש- $\hat{\mu}_n$ מוגדר כפונקציית סבירות של מוקד סטטיסטי.

אנו מודים לך על תרומותך ותומךך. מטרתנו היא לסייע לך בפתרון בעיות טכניות. אם יש לך שאלות או מושגויות, אנא נאלה ותפקידך הוא לסייע לנו. מטרתנו היא לסייע לך בפתרון בעיות טכניות. אם יש לך שאלות או מושגויות, אנא נאלה ותפקידך הוא לסייע לנו.

$$\mathbb{E}(\hat{\mu}_n(x_1, \dots, x_n)) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^n x_i\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(x_i) = \frac{1}{n} \cdot \sum_{i=1}^n \mu = \mu$$

$$P(|\hat{\mu}_n - E(\hat{\mu}_n)| > \varepsilon) \leq \frac{Var(\hat{\mu}_n)}{\varepsilon^2}$$

$\text{Var}(X_i) = \sigma^2$ ר'פ'נ'ס ס'כ, ד' מ' פ'ר'ג'ן ס'ע ר'ג'לן ו' נ' σ^2 נ'ו'ג'ר'ס

$$\text{Var}(\hat{\mu}_n(x_1, \dots, x_n)) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n x_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n x_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(x_i) = \frac{1}{n^2} \cdot n \cdot \sigma^2 = \frac{\sigma^2}{n}$$

• *ay/gf m137 var -> a/c n/gf g* /*ij sic , w/152 r' p/ xij/ l /11.2w*

$$P(|\hat{\mu}_n(x_1, \dots, x_n) - \mu| > \varepsilon) \leq \frac{\frac{\sigma^2}{n}}{\varepsilon^2} = \frac{\sigma^2}{n \cdot \varepsilon^2} \xrightarrow{n \rightarrow \infty} 0 \quad : \varepsilon > 0 \text{ ֆակտ քաշված է } \sigma^2$$

由 $\hat{\mu}_n$ 的定义知 $\hat{\mu}_n$ 是 μ 的一致估计量，即 $P(|\hat{\mu}_n - \mu| > \varepsilon) \rightarrow 0$ 为 $n \rightarrow \infty$ 时的必然事件。

9. Let $\mathbf{x}_1, \dots, \mathbf{x}_m \stackrel{iid}{\sim} \mathcal{N}(\mu, \Sigma)$ be m observations sampled i.i.d from a multivariate Gaussian with expectation of $\mu \in \mathbb{R}^d$ and a covariance matrix $\Sigma \in \mathbb{R}^{d \times d}$. Derive the log-likelihood function of $\mathcal{N}(\mu, \Sigma)$. Hint: follow the approach used to derive the likelihood function for the univariate case.

לעתים מוגדרת גודל-הטבלה כפונקציית נורמליזציה של סט נתונים.

$$f(x) = \frac{1}{\sqrt{(2\pi)^d |\Sigma|}} \cdot \exp\left(-\frac{1}{2}(x-\mu)^\top \Sigma^{-1}(x-\mu)\right)$$

לפיה $\theta = (\hat{\mu}, \hat{\Sigma})$: כלומר $\hat{\mu}$ ו- $\hat{\Sigma}$ הם אמצע ו-קוטר העדשה. θ מוגדר כפונקציית מילוי של x_1, \dots, x_n .

$$L(\theta | x_i) = f_{\theta}(x_i) = \frac{1}{\sqrt{(2\pi)^d |\hat{\Sigma}|}} \cdot \exp\left(-\frac{1}{2}(x_i - \hat{\mu})^\top \hat{\Sigma}^{-1} (x_i - \hat{\mu})\right)$$

בנוסף לדוגמה של פונקציית סטטיסטיקה, נזכיר את הדוגמה של פונקציית סטטיסטיקה T , אשר מוגדרת כפונקציה מ- Ω ל- \mathbb{R} . פונקציית סטטיסטיקה T מוגדרת כפונקציה מ- Ω ל- \mathbb{R} .

$$L(\theta | x_1, \dots, x_n) = \prod_{i=1}^n f_{\theta}(x_i)$$

: log-likelihood ↗ 3p10

$$\log L(\theta | x_1, \dots, x_n) = \log \left(\prod_{i=1}^n f_\theta(x_i) \right) = \sum_{i=1}^n \log f_\theta(x_i) =$$

$$= n \log \left(\frac{1}{\sqrt{(2\pi)^d |\hat{\Sigma}|}} \right) + \sum_{i=1}^n \left(-\frac{1}{2} (x_i - \hat{\mu})^\top \hat{\Sigma}^{-1} (x_i - \hat{\mu}) \right)$$

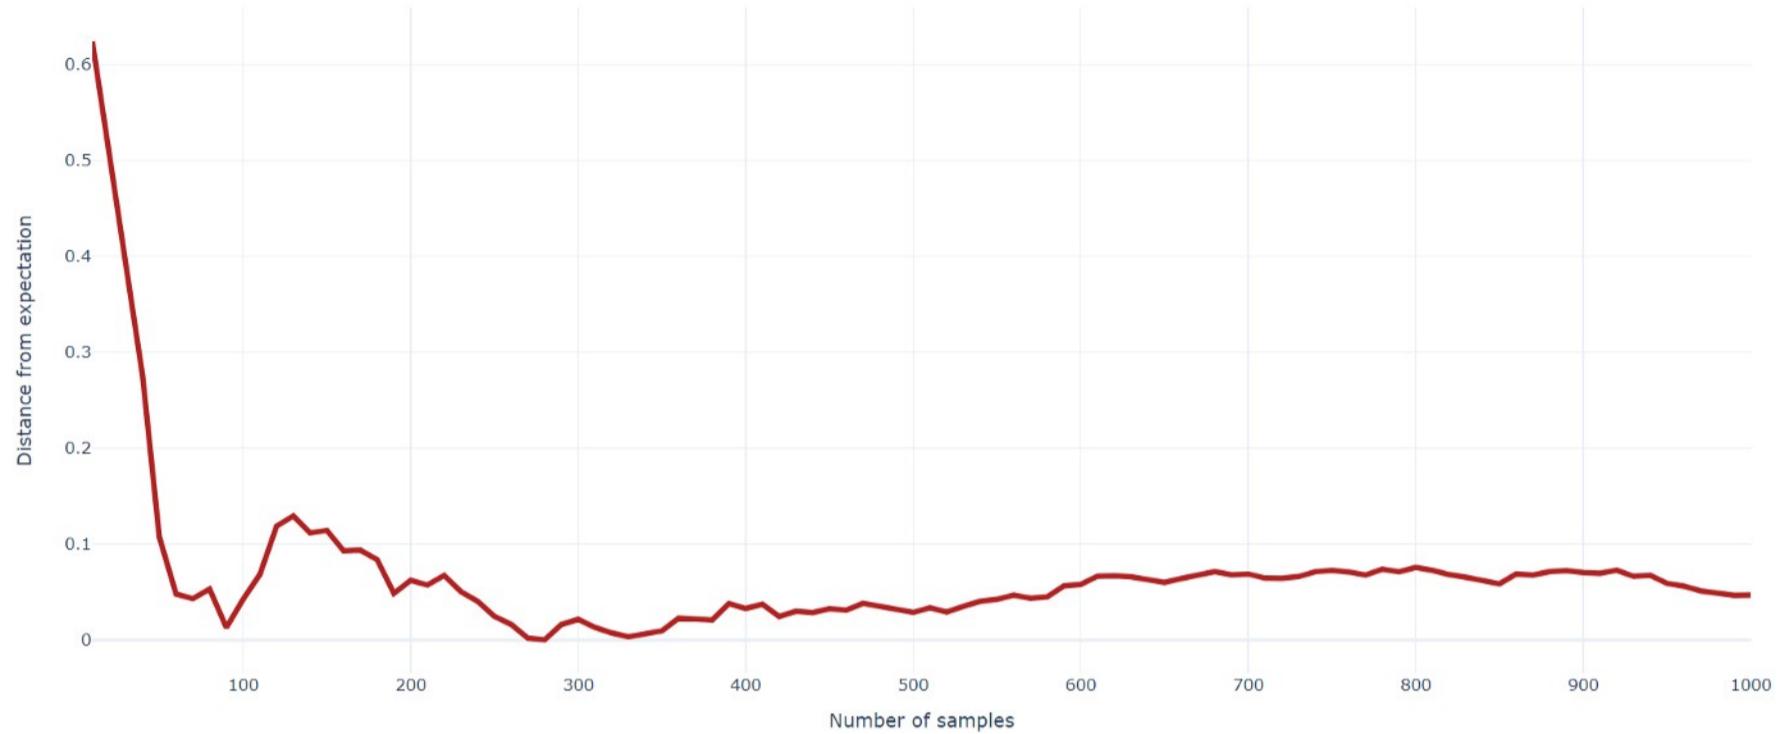
גרפים לחולק המעשיות:

שאלה 1:

(0.9752096659781323 , 9.954743292509804)

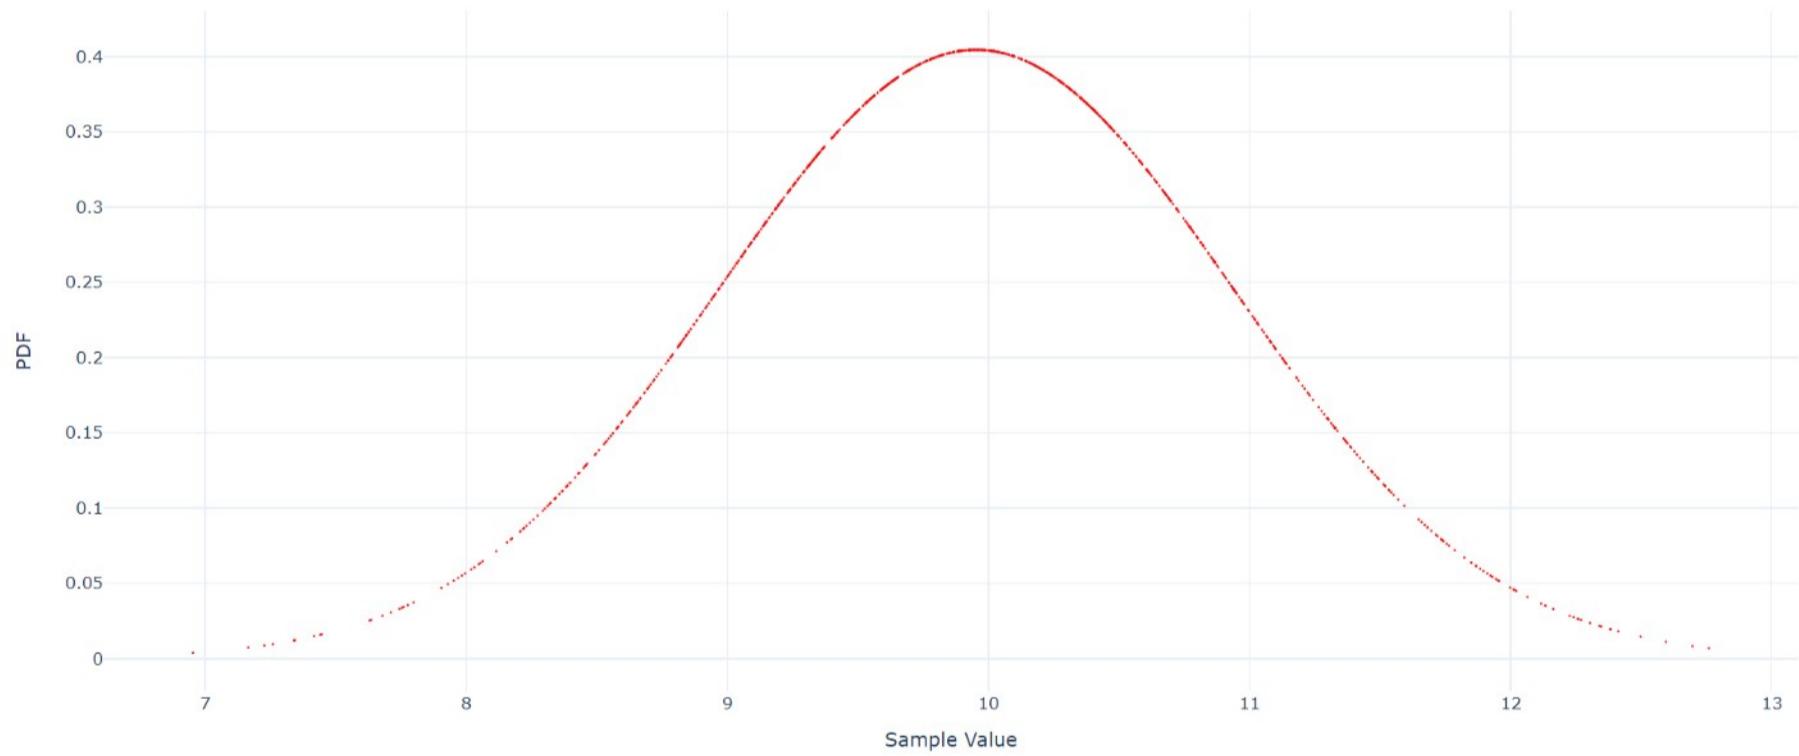
שאלה 2:

Absolute distance between estimated- and true expectation



שאלה 3:

PDF for each sample drawn



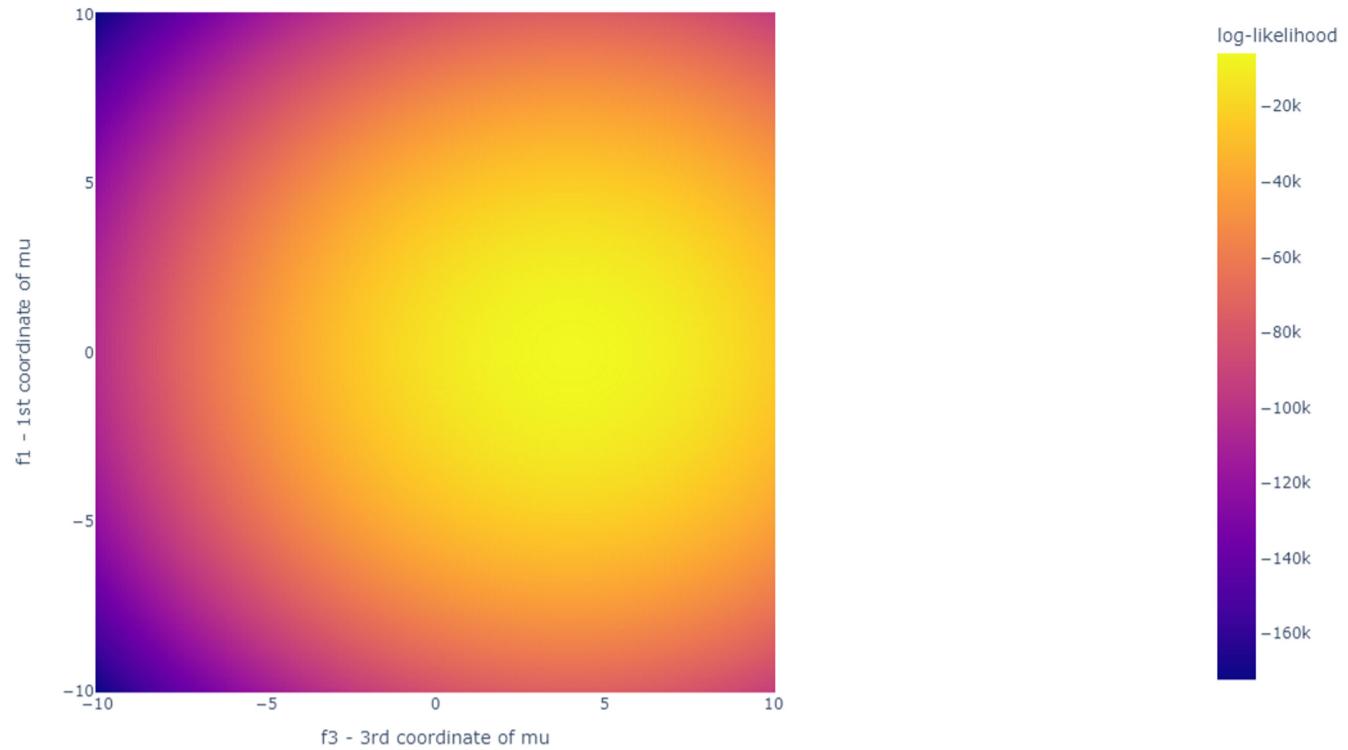
ההגרף ניתן לראות שפונקציית הצפיפות המתקיים היא בצורה של ההטפלות נורמלית עם ממוצע שיטוטה ורק במעט מהערך האמתי של 10. זה הגיוני כיון שהדגימות אכן הגיעו מהטפלות נורמלית והתחולות של פונקציית ההטפלות ממנה נדגמו הייתה 10.

שאלה 4:

[0.02038981- 3.9932571 0.04313959- 0.02282878-
,[0.04557631130140597 ,0.005877889086032535- ,1.974182797387516 ,0.16634443759233586] , [0.4628827064594544 ,0.030275629165979034- ,0.16634443759233586 ,0.9166760774999685]]
[[0.9725372963099224 ,0.020366857161867046- ,0.04557631130140597 ,0.4628827064594544] , [0.020366857161867046- ,0.9796027125646046 ,0.005877889086032535- ,0.030275629165979034-]

שאלה 5

Heatmap of log-likelihood under varying values of mu



מהגרף למדנו שאכן הערך המקסימלי של $\log\text{-likelihood}$ מתקיים באזורי של $f_1=0, f_3=4$. אלו אכן הפרמטרים האמיטיים של ההתפלגות ממנה הדגימות הגיעו, ולכן הגיוני שהלערכים אלו תהיה נראות מקסימלית.

שאלה 6:

The f_1, f_3 values which yielded maximal likelihood: -0.050 3.969